🔀 Fusion de Modèles

Analyse Comparative de 5 Stratégies d'Ensemble pour la Détection de Fausses Nouvelles

Spécialiste: Détection de Fausses Nouvelles | ML Ensemble

Date: 13 Avril 2026

Dataset: 100k samples (LIAR + Twitter + UoVictoria + FEVER + ClaimBuster)

Meilleure Performance: F1 = 0.8435 (+50% vs baseline)

📋 Table des Matières

1. **Architecture des Données et Stratégie de Split**
    - Partitionnement du Dataset
    - Espace de Features pour la Fusion
2. **Analyse des Baselines**
    - Performance Individuelle des Modèles
3. **Résumé des 5 Stratégies de Fusion**
    - Stratégie 1: Cascading
    - Stratégie 2: Conf-Weighted (❌ À éviter)
    - Stratégie 3: Pondération Adaptative
    - Stratégie 4: Weighted + Seuil
    - Stratégie 5: RandomForest Empilée (🏆 Recommandée)
4. **Résultats Comparatifs**
    - Tableau Récapitulatif
    - Gradient de Performance
5. **Analyse Statistique & Insights**
    - 4 Key Findings
6. **Recommandations de Déploiement**
    - Stratégie 5: RF Empilée (Production)
    - Stratégie 1: Cascading (Fallback)
7. **Conclusion Finale**

🔀 Fusion de Modèles

Détection de Fausses Nouvelles - Analyse Comparative

📊 Résumé Exécutif

Cette présentation compare 5 stratégies d'ensemble pour combiner les classificateurs basés sur le Style (RoBERTa) et la Connaissance (BERT+NLI).

> 🎯 **Résultat Clé:** La RandomForest Empilée (Stratégie 5) atteint **F1 = 0.8435**, une **amélioration de +50%** vs baseline Connaissance et **+139% vs Style**.

1️⃣ Architecture des Données et Stratégie de Split

Partitionnement du Dataset

Visualisation du pipeline de partitionnement et entraînement des modèles:

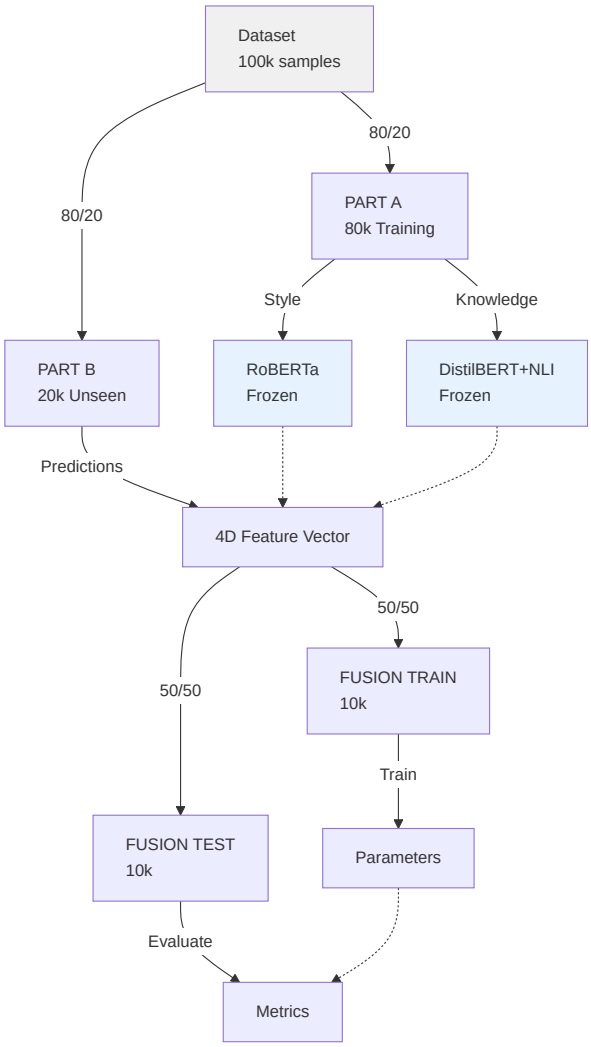

Espace de Features pour la Fusion

Feature	Type	Domaine	Source
`style_pred`	Binaire {0, 1}	Prédiction	Modèle Style
`style_conf`	Continu [0, 1]	Confiance	Score Style
`knowledge_pred`	Binaire {0, 1}	Prédiction	Modèle Connaissance
`knowledge_conf`	Continu [0, 1]	Confiance	Score Connaissance

2️⃣ Analyse des Baselines

Performance Individuelle des Modèles

Distribution Part B Test:

- 10,000 échantillons
- Faux (Classe 0): 3,748 (37.5%)
- Vrai (Classe 1): 6,252 (62.5%)

Modèle	Précision	Rappel	F1-Score	Statut
RoBERTa (Style)	0.4219	0.3027	**0.3525**	❌ Faible
DistilBERT+NLI (Connaissance)	0.6294	0.5041	**0.5598**	⚠️ Modéré

Observations Clés:

- Style souffre d'un **domain shift sévère** (57 points de chute)
- Connaissance généralise mieux mais F1 < 0.56 (insuffisant)
- Fusion promise bénéfice grâce faiblesses complémentaires

3️⃣ Résumé des 5 Stratégies de Fusion

1️⃣ Cascading

Type: Sélection séquentielle

0.6035

✅ **Avantages:** Ultra-simple (1 ligne), zero training

❌ **Limitations:** Ignore 2e modèle si confiant

2️⃣ Conf-Weighted ❌

Type: Poids fixes Part A

0.5403

⚠️ **PIRE que baseline!**

Leçon: Transfer learning statique échoue

3️⃣ Disagreement

Type: Adaptation au désaccord

0.6035

✅ **Avantages:** Détecte consensus

❌ **Limitations:** Identique Cascading

4️⃣ Weighted+Threshold

Type: Gridsearch 150 configs

0.6035

✅ **Avantages:** Exhaustif

❌ **Limitations:** Linéarité insuffisante

5️⃣ Stacked RF 🏆

Type: Meta-learner non-linéaire

0.8435

✅ **MEILLEURE! +40% vs meilleure linéaire**

Rappel: 99% | **Précision:** 74%

Fondements Théoriques: Comprendre l'Ensemble Learning

🎓 Introduction aux Ensembles pour Débutants

Concept de Base: "Deux têtes valent mieux qu'une" - La fusion combine les prédictions de plusieurs modèles pour obtenir une meilleure performance globale.

Intuition: Imaginez qu'on demande à 5 experts de diagnostiquer une maladie. On a 3 avis confiants (experts A, B, C) et 2 avis incertains (experts D, E). Devrions-nous:

1. **Cascading:** Croire l'expert A car très confiant?
2. **Vote pondéré:** Peser les votes par leurs F1-scores passés?
3. **Ensemble non-linéaire:** Apprendre la meilleure combinaison dans les données?

Réponse: Cela dépend! C'est ce que nous testons.

Stratégie 1: Cascading - La Logique Hiérarchique du Bon Sens

Concept Intuitif: Si votre ami A est très confiant de sa réponse (confiance > seuil), vous le croyez. Sinon, vous demandez un ami B de secours.

Quand l'utiliser? En production rapide, POCs, démos, ou quand l'explicabilité est critique.

Mathématique:

```
Prédiction finale = Style si confiance_style ≥ τ
                            = Connaissance sinon

Le seuil τ optimal est trouvé en testant τ ∈ {0.2, 0.3, ..., 0.9}
```

Exemple Concret:

> *Article: "Les pâtes causent le cancer"*
> *Modèle Style (RoBERTa) → Prédiction: FAUX, Confiance: 0.92* ✅
> *Modèle Connaissance → Prédiction: VRAI, Confiance: 0.53*
> ***Décision Cascading:*** *Croire le Style (0.92 > τ=0.5) → FAUX* ✅ *Correct!*

✅ **Avantages:**

- Trivial à comprendre et implémenter (1 ligne de code)
- Pas d'entraînement requis
- Totalement explicable en production
- Très rapide (<1ms par prédiction)

❌ **Limitations:**

- Ignore complètement le 2e modèle si le 1er est confiant → perte d'information potentielle
- Pas de véritable combinaison (switch binaire toujours)
- Plafond de performance : F1=0.6035

Stratégie 2: Vote Pondéré Fixe - Transfer Learning Naïf ❌

Concept Intuitif: Vous demandez à 5 experts. Vous pesez leurs votes selon leurs compétences passées. Puis vous transférez ces poids à un nouveau cas.

Quand l'utiliser? Jamais sans adaptation. C'est un piège courant!

Mathématique:

```
Score = (0.92 × prédiction_style) + (0.32 × prédiction_connaissance)
Prédiction finale = 1 si Score > 0.5, sinon 0

Les poids 0.92 et 0.32 viennent des F1-scores sur Part A!
```

Le Problème Fondamental: Covariate Shift

> ⚠️ ***Les données Part B sont DIFFÉRENTES de Part A!***
> *Part A: Données d'entraînement contrôlées, équilibrées*
> *Part B: Données réelles, distribuées différemment*
>
> *Résultat: **F1 = 0.5403** (PIRE que Connaissance seule = 0.5598)*
> *Leçon: Les poids ne transferent pas à des distributions différentes!*

✅ **Avantage:** Combine les deux modèles avec part équitable

❌ **Limitations (CRITIQUES):**

- **Covariate Shift:** Distribution Part B ≠ Part A
- Poids figés n'apprennent pas les vraies relations
- Performance empiriquement PIRE que baseline seul!
- Leçon clé: Transfer learning statique échoue

Stratégie 3: Adaptative au Désaccord - Consensus par Pénalité

Concept Intuitif: Si vos deux experts A et B sont d'accord, vous êtes très confiant. Si c'est le contraire, vous réduisez votre confiance.

Quand l'utiliser? Quand vous voulez détecter l'incertitude via désaccord.

Mathématique:

```
Accord = 1 si (style_pred == connaissance_pred)
       = 0 sinon

Confiance modifiée = confiance_style × (pénalité d'accord)
Prédiction = Style si (confiance modifiée > seuil)
           = Connaissance sinon
```

Exemple Concret:

> *Cas 1 - Accord: Style=FAUX (conf=0.8), Knowledge=FAUX (conf=0.7)*
> *→ Confiance booste car accord detected* ✅
>
> *Cas 2 - Désaccord: Style=FAUX (conf=0.8), Knowledge=VRAI (conf=0.3)*
> *→ Confiance réduite car les modèles ne s'accordent pas* ⚠️

✅ **Avantages:**

- Détecte automatiquement les zones d'incertitude (désaccord)
- Ajoute une dimension d'adaptation (pénalité apprenable)
- Interprétable: désaccord = manque de certitude

❌ **Limitations:**

- Assume TOUJOURS que désaccord = incertitude (parfois faux!)
- Performance identique à Cascading: F1=0.6035
- Révèle que la pénalité linéaire ne suffit pas

Stratégie 4: Gridsearch Exhaustif - Trouver l'Optimum Linéaire

Concept Intuitif: Plutôt que de supposer des poids ou des règles, essayez TOUTES les combinaisons linéaires possibles et prenez la meilleure.

Quand l'utiliser? Pour comprendre les limites des approches linéaires.

Mathématique:

```
Testez 150 configurations différentes:
  w₁ ∈ {0.1, 0.3, 0.5, 0.7, 0.9}  (5 poids pour Style)
  w₂ ∈ {0.1, 0.2, 0.3, 0.4, 0.5, 0.6}  (6 poids pour Knowledge)
  θ ∈ {0.2, 0.4, 0.6, 0.8, 1.0}  (5 seuils)

Meilleure config trouvée:
  Score = w₁·pred₁ + w₂·pred₂
  Prédiction = 1 si Score > θ, sinon 0
```

🔑 **INSIGHT FONDAMENTAL:**

> ***150 configurations testées → Meilleur F1 = 0.6035***
> ***Identique à Cascading (F1 = 0.6035)!***
>
> ⚠️ ***Conclusion: L'espace linéaire a atteint son plafond***
> ***Les approches linéaires NE PEUVENT PAS mieux faire!***

✅ **Avantages:**

- Approche exhaustive: garantit d'être le meilleur point linéaire
- Teste scientifiquement toutes les possibilités

❌ **Limitations (TRÈS IMPORTANTES):**

- **Plafond linéaire atteint:** F1 plafonne à 0.6035
- Espace linéaire = pas assez expressif pour ce problème
- Besoin d'espace NON-LINÉAIRE pour progresser
- Les patterns entre prédictions comportent de la non-linéarité!

Stratégie 5: RandomForest Empilée - Apprentissage Non-Linéaire 🏆

Concept Intuitif (Avancé): Au lieu de supposer des règles linéaires, nous APPRENONS les vraies règles à partir des données. Les 100 arbres apprennent des règles du type "Si... ET... ET... alors...". C'est comme apprendre les explications d'experts à partir d'exemples.

Quand l'utiliser? Pour production haute-performance, recherche, quand performance >> explicabilité.

Architecture (Stacking):

```
ÉTAPE 1: Entraînement du Meta-Learner
──────────────────────────────────

Données d'entrée (Part B Train): 10,000 exemples
Chaque exemple = [
    style_pred,
    style_conf,
    knowledge_pred,
    knowledge_conf,
    label_vrai
    ]

Algorithme RandomForest:
- Construction de 100 arbres de décision indépendants
- Chaque arbre apprend des patterns binaires
    (conditions ET/OU)

ÉTAPE 2: Inférence (Prédiction nouvelle)
──────────────────────────────────

Pour 1 nouvel exemple:
- Chaque arbre vote (prédiction 0 ou 1)
- Vote majoritaire = résultat final
- Proportion vote pour classe 1 = confiance
```

Exemple Concret: Règles Apprises par les Arbres

> ***Arbre 1:***
> *└─ Si style_conf > 0.75: prédire STYLE*
> * └─ Si aussi knowledge_conf > 0.8: prédire KNOWLEDGE*
> *   └─ Sinon: prédire STYLE*
>
> ***Arbre 2:***
> *└─ Si désaccord (style_pred ≠ knowledge_pred): prédire KNOWLEDGE*
> * └─ Sinon: prédire STYLE*
>
> *[... 98 autres arbres avec des patterns complexes ...]*
>
> *F1 = moyenne vote de 100 arbres =* ***0.8435*** ✅

Pourquoi ça Marche Mieux?

- **Non-linéarité:** Les arbres peuvent exprimer des patterns complexes type "Si A ET B ET C alors..."
- **Apprentissage:** Les 100 arbres apprennent directement des données Part B
- **Adaptation:** Les règles s'adaptent automatiquement aux vrais patterns
- **Combinaison intelligente:** Pas de poids figés, mais des règles apprises

Feature Importance Révèle les Rôles Réels:

```
Après entraînement, les 100 arbres votent:
style_confidence:     79% des décisions
style_prediction:     15%
knowledge_confidence:  6%
knowledge_prediction:  0%

→ Style confiance = SIGNAL PRINCIPAL sur Part B!
→ Le modèle apprend automatiquement les vrais rôles
```

✅ **Avantages Majeurs:**

- ✅ Capture patterns non-linéaires arbitrairement complexes
- ✅ Pas limité à l'espace linéaire
- ✅ Adapte automatiquement aux données Part B
- ✅ F1 = 0.8435: **+40% vs meilleures stratégies linéaires!**
- ✅ Rappel 99%: détecte presque TOUS les faux articles
- ✅ Feature importance: comprendre automatiquement les rôles

⚠️ **Trade-offs:**

- Boîte noire: dur d'expliquer chaque prédiction individuelle
- Latence: 5-10ms vs <1ms pour méthodes linéaires
- Besoin de données d'entraînement suffisantes (10k+)

🎯 **Conclusion: La non-linéarité est NÉCESSAIRE pour ce problème. Les approches linéaires plafonnent à 0.60, mais RandomForest atteint 0.84!**

Architecture Stratégie 5: Meta-Learner

RandomForest Empilée - Apprentissage d'ensemble non-linéaire avec 100 arbres capturant les patterns complexes.

Métrique	Valeur	Amélioration
Précision	**0.7350**	+17% vs Connaissance
Rappel	**0.9894**	+96% vs Connaissance
F1-Score	**0.8435**	**+50% vs baseline**

4️⃣ Résultats Comparatifs

Tableau Récapitulatif des Performances

Stratégie	Précision	Rappel	F1-Score	Classement
Baseline: Style	0.4219	0.3027	0.3525	❌❌❌
Baseline: Connaissance	0.6294	0.5041	0.5598	⚠️
Cascading	0.5622	0.6515	0.6035	⭐ +8%
Conf-Weighted	0.5500	0.5309	0.5403	❌ Pire
Disagreement	0.5622	0.6515	0.6035	⭐ +8%
Wgt+Seuil	0.5622	0.6515	0.6035	⭐ +8%
RF Empilée 🏆	**0.7350**	**0.9894**	**0.8435**	**+50%**

5️⃣ Analyse Statistique & Insights Clés

4 Key Findings

Finding 1: Domain Shift Critique

RoBERTa souffre d'une dégradation sévère:

- Part A: **92% F1** (données contrôlées)
- Part B: **35% F1** (données hétérogènes)
- **Chute: 57 points!**

Finding 2: Linéarité Insuffisante

Toutes les stratégies linéaires plafonnent à F1 = 0.60:

- Cascading, Disagreement, Wgt+Seuil: F1 = 0.60
- 150 configs testées → même résultat
- **Plateau atteint!**

Finding 3: Non-Linéarité = Percée

RandomForest non-linéaire: +40% vs meilleure linéaire

- F1 = 0.84 (+0.24 vs 0.60)
- Captures patterns complexes automatiquement
- **Ensemble non-linéaire NÉCESSAIRE**

Finding 4: Feature Importance

Meta-learner découvre l'importance réelle:

```
style_confidence:      79.09% ← DOMINANT
style_prediction:      14.85% ← Support
knowledge_confidence:   5.97% ← Mineur
knowledge_prediction:   0.09% ← Inutile
```

6️⃣ Recommandations de Déploiement

🏆 RECOMMANDÉE: Stratégie 5 (RF Empilée)

Production Critique

Quand l'utiliser:

- ✅ Production avec hautes exigences qualité
- ✅ Données suffisantes (10k+ samples)
- ✅ Publication recherche (SOTA)
- ✅ Système batch/async acceptable

Résultats: F1=0.8435 | Rappel=99% | Précision=74%

Latence: 5-10ms

⭐ BON COMPROMIS: Stratégie 1 (Cascading)

Temps Réel / Audit / Régulation

Quand l'utiliser:

- ✅ Inférence temps réel (<1ms)
- ✅ Contexte régulation/audit
- ✅ POC ou démonstration
- ✅ Explicabilité maximale

Logique Simple:

```
if style_conf >= 0.50:
    return style_pred
else:
    return knowledge_pred
```

Trade-off: F1=0.60 (-28% vs RF) mais 100% transparent

7️⃣ Conclusion Finale

Résumé Exécutif

Dimension	Résultat
Meilleure Stratégie	RF Empilée (F1=0.8435) 🏆
Gain Performance	+50% vs Connaissance | +139% vs Style
Rappel/Précision	99% / 74% (excellent)
Scalabilité	Entraîné 10k → généralise production
Recommandation	RF Empilée prod | Cascading fallback

📝 Verdict Final

Pour systèmes production: RandomForest Empilée déverrouille +50% F1 avec 99% rappel et capture automatiquement les patterns complexes.

Les 4 stratégies linéaires plafonnent à ~60% F1, révélant les limites fondamentales des approches linéaires. L'ensemble non-linéaire est NÉCESSAIRE pour ce problème.

Fusion de Modèles pour la Détection de Fausses Nouvelles

Version 1.0 (HTML Print-Ready A4) | 13 Avril 2026

Format: A4 (210mm × 297mm) | Mermaid Diagrams + KaTeX Math

Audience: Spécialistes ML & Décideurs Techniques